Департамент образования и науки города Москвы Государственное автономное образовательное учреждение высшего образования города Москвы «Московский городской педагогический университет» Институт цифрового образования Департамент информатики управления и технологий

# Агафонов Антон Александрович БД-241м

# Практическая работа 1. Введение в большие данные и их хранение. Инструменты обработки больших данных (Hadoop)

Направление подготовки/специальность

38.04.05 - Бизнес-информатика

Бизнес-аналитика и большие данные

(очная форма обучения)

Вариант 1

Москва

### Цель

Изучить основные операции и функциональные возможности системы, что позволит понять принципы работы с данными и распределенными вычислениями.

#### Основная часть

Запускаем hadoop

Start-dfs.sh

```
hadoop@devopsvm:~$ sudo su - hadoop
[sudo] password for devops:
hadoop@devopsvm:~$ start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [devopsvm]
2025-03-30 21:59:50,217 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable hadoop@devopsvm:~$
```

Рис.1 Запускаем файловую систему

## Start-yarn.sh

Проверяем запущенные службы командой

jps




Рис.2 Проверка запущенных служб

Проверяем доступность запущенных систем

Переходим по ссылке для проверки запущен ли dfs по ссылке

Localhost:9870/dfshealth.html#tab-overview




Рис.3 проверка доступности систем

Проверяем запущен ли yarn по ссылке

Localhost:8088/cluster




Рис.4 Проверка работы yarn

Создаем пользователя и каталог командой

Hdfs dfs -mkdir -p /agafonov01/Hadoop/input

```
hadoop@devopsvm: ~
 F
           hadoop@devopsvm: ~
                                               devops@devopsvm
devops@devopsvm:~$ sudo su - hadoop
[sudo] password for devops:
hadoop@devopsvm:~$ start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [devopsvm]
library for your platform... using builtin-java classes where
hadoop@devopsvm:~$ start-yarn.sh
Starting resourcemanager
Starting nodemanagers
hadoop@devopsvm:~$ jps
4976 NodeManager
3281 NameNode
3479 DataNode
3672 SecondaryNameNode
5340 Jps
4845 ResourceManager
hadoop@devopsvm:~$ hdfs dfs -mkdir -p /agafonov01/hadoop/input
2025-03-30 22:09:24,247 WARN util.NativeCodeLoader: Unable to l
library for your platform... using builtin-java classes where
hadoop@devopsvm:~$
```

Рис. 5 Создание пользователя




Рис. 6 Проверка созданного пользователя

#### Скачиваем данные

#### wget

https://raw.githubusercontent.com/BosenkoTM/Distributed\_systems/main/practice/2 024/I w\_01/GDP.csv




Рис.7 Скачиваем данные

Создаем каталог для данных

Hdfs dfs -mkdir -p /agafonov01/Hadoop/input/economic\_data




Рис.8 Создание каталога economic\_data




Рис.9 Проверка созданного каталога economic\_data

Size

Group

supergroup 0 B

Last

Modified

Mar 30

22:22

If Block If

Size

0 B

Previous

Replication

0

11

economic\_data 🗂

Name

Next

Переносим данные в каталог

抽

Permission

drwxr-xr-x

Showing 1 to 1 of 1 entries

Owner

hadoop

Hdfs dfs -put GDP.csv /agafonov01/Hadoop/input/economic\_data

```
Mar 30 22:31
                                hadoop@devopsvm: ~
           hadoop@devopsvm: ~
                                                 hadoop@devopsvm: ~
systems/main/practice/2024/lw 01/GDP.csv
--2025-03-30 22:18:16-- https://raw.githubusercontent.com/BosenkoTM/Distributed
systems/main/practice/2024/lw 01/GDP.csv
Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.109.1
33, 185.199.108.133, 185.199.111.133, ...
Connecting to raw.githubusercontent.com (raw.githubusercontent.com)|185.199.109.
133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 30268 (30K) [text/plain]
Saving to: 'GDP.csv'
GDP.csv
                   in 0.02s
2025-03-30 22:18:16 (1.42 MB/s) - 'GDP.csv' saved [30268/30268]
devops@devopsvm:~$ sudo su - hadoop
[sudo] password for devops:
hadoop@devopsvm:~$ hdfs dfs -mkdir -p /agafonov01/hadoop/input/economic_data
2025-03-30 22:22:03,053 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
hadoop@devopsvm: $ hdfs dfs -put GDP.csv /agafonov01/hadoop/input/economic_data/
2025-03-30 22:31:22,343 WARN util.NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicable
```

Рис. 10 Перенос данных в каталог




Рис.11 Проверка перенесенных данных

Задаем права доступа

hdfs dfs -chmod 777 /agafonov01/hadoop/input/economic\_data





Рис.12 Устанавливаем права доступа

Обрабатываем данные при помощи Spark

Spark-shell



**Рис.13** Запуск spark

Загружаем данных из hdfs

# val data = spark.read.option("header", "true").csv("file:///home/hadoop/GDP.csv")

```
scala> val data = spark.read.option("header","true").csv("file:///home/hadoop/GD
P.csv")
data: org.apache.spark.sql.DataFrame = [Country: string, Year: string ... 21 mor
e fields]
scala>
```

## Проверка полученной схемы данных

## data.printSchema()




Рис.15 Выводим схему

Вычисление среднего значения GDP

val result = data.selectExpr("avg(GDP) as avg\_GDP")

```
scala> val result=data.selectExpr("avg(GDP) as avg_GDP")
result: org.apache.spark.sql.DataFrame = [avg_GDP: double]
scala>
```

Рис.16 Вычисление среднего значения GDP

Сохраняем результата в CSV файл

result.write.option("header", "true").csv("/home/hadoop/output/avg GDP.csv")




Рис.17 сохранение результатов

Переходим в директорию с результатами

cd /home/hadoop/output/avg GDP.csv




Рис.18 Проверяем полученный файл

Загружаем полученный файл в HDFS

hdfs dfs -put /home/hadoop/output/avg\_GDP.csv /agafonov01/hadoop/input/




Рис.19 Проверка загруженного файла в hdfs

Проверка загрузки

hdfs dfs -ls /user01/hadoop/input/

```
hadoop@devopsvm:~/output/avg_GDP.csv$ hdfs dfs -ls /agafonov01/hadoop/input
2025-03-30 23:57:42,223 WARN util.NativeCodeLoader: Unable to load native-hadoop library
for your platform... using builtin-java classes where applicable
Found 2 items
-rw-r--r-- 1 hadoop supergroup 27 2025-03-30 23:55 /agafonov01/hadoop/input/avg
_GDP.csv
drwxrwxrwx - hadoop supergroup 0 2025-03-30 22:31 /agafonov01/hadoop/input/eco
nomic_data
hadoop@devopsvm:~/output/avg_GDP.csv$
```


Рис.20 Проверка загрузки

## Задание для самостоятельной работы

Подключиться к HDFS и убедиться, что файл доступен по пути hdfs://localhost:9000/agafonov01/hadoop/economic data/GDP.csv

Запускаем jupyterlab и загружаем файлы из hdfs

File\_path= "hdfs://localhost:9000/agafonov01/Hadoop/input/economic\_data/GDP.csv" df = spark.read.csv(file\_path, header=True, inferShema =True ) df.show(5)



#### Индивидуальное задание

#### Вариант 1

https://raw.githubusercontent.com/BosenkoTM/Distributed\_systems/main/practice/2 024/I w\_01/AAPL.csv

Для начала создаем каталог в hdfs

## Hdfs dfs -mkdir -p /agafonov01/hadoop/input/vol



Рис.21 Создание каталога surgutneftgaz в hdfs

Переносим файл из пользователя devops в пользователя Hadoop

sudo mv /home/devops/Desktop/AAPL.csv /home/hadoop

Переносим данные в каталог

## Hdfs dfs -put AAPL.csv /agafonov01/Hadoop/input/vol




Рис.22 Переносим данные об акциях в hdfs

#### Устанавливаем права доступа

## hdfs dfs -chmod 777 /agafonov01/hadoop/input/vol

```
hadoop@devopsvm:~$ hdfs dfs -chmod 777 /agafonov01/hadoop/input/vol
2025-04-08 02:02:08,618 WARN util.NativeCodeLoader: Unable to load native-hadoo
library for your platform... using builtin-java classes where applicable
hadoop@devopsvm:~$
```

#### Рис.23 Устанавливаем права доступа

Загружаем данные из hdfs

Import pandas as pd

Import matplotlib.pyplot as plt

From pyspart.sql import SparkSession

Spark = SparkSession.builder\

.appName("Economic Data Analysis")\

.config("spark.hadoop.fs.defaultFS","hdfs://localhost:9000")\

.get0Create()

Spark.conf.set("spark.sql.shuffle.partition", "50")

File\_path = "hdfs://localhost:9000/agafonov01/Hadoop/input/vol/AAPL.csv

Df= spark.read.csv(file\_path, header = True, inferSchema =True)

# Df.show(5)

# 1	.appNa .confi .confi .get0	ame("E ig("sp ig("sp rCreat	conomi ark.ha ark.ui e()	builder \ c Data Analysis" doop.fs.defaultF .port", "4050")  a pasgenos gns s .sql.shuffle.par	S", "hdf:	пераций	host:90	) \													
fil	= spark	= "hd c.read	fs://li l.csv(f	FS ocalhost:9000/ag ile_path, header ок данных																	
df.	show(5)	= df.		las()															6	Λ 4	÷
par par	show(5)	= df. head(	)		Industry	Business	Mining	Manufacturing	Electricity_supply	Water_supply	_ ^	Accommodation	Information	Financial	Real estate	Professional_scientific	Administrative	Education		. 10.51	
par par	show(5)	= df. head( Year	GDP	Urban_population	Industry 24.0	Business 25.2	Mining 18.3	Manufacturing				Accommodation 9.9	Information 21.2	Financial 30.3	Real estate				Human_health	. 10.51	Oth
df. par par	show(5) ndas_df ndas_df Country	= df. head( Year 2010	GDP 35390	Urban_population 57.40					23.6	12.2						34.0	22.5	27.8	Human_health	Arts	Oth 3
par par	show(5) ndas_df ndas_df Country Austria	= dfhead( Year 2010 2015	GDP 35390 36140	Urban_population 57.40 57.72	24.0	25.2	18.3	24.4	23.6 17.6	12.2	-	9.9	21.2	30.3	27.0	34.0 31.3	22.5 20.0	27.8 24.2	Human_health 12.0 12.9	Arts 34.0	Oth 3,
par par	ndas df ndas df Country Austria	= df. head( Year 2010 2015 2016	35390 36140 36390	Urban_population 57.40 57.72	24.0	25.2 23.4	18.3	24.4 22.7	23.6 17.6 13.2	12.2 9.3 8.2		9.9 6.4	21.2	30.3 30.3	27.0 28.0	34.0 31.3 30.4	22.5 20.0 17.8	27.8 24.2 24.3	Human_health 12.0 12.9 14.5	Arts 34.0 26.2	32 28 27

## Заключение

В ходе проделанной лабораторной работы, были изучены основные операции и функциональные возможности системы, что позволило понять принципы работы с данными и распределенными вычислениями, также было выполнено задание по вариантам.